

Prototipo BI asistido por inteligencia artificial

Informe del Sprint 6

Contexto multifuente y validación universal

Ciclo completo desde metadatos hasta analítica
con fuentes SQL Server independientes

Responsables	Emily Dayan Robles Alvarado y Lesly Samay Velásquez Anchundia
Código documental	INF-SPR-06
Versión	1.0.1
Fecha de cierre	1 de octubre de 2026
Rama de trabajo	feature/multi-source-sqlserver
Estado	Incremento funcional validado localmente
Repositorio	LFXAS/prototipo-bi-ia

Índice

1	Resumen ejecutivo	1
2	Objetivo, alcance y definición de terminado	1
2.1	Objetivo del incremento	1
2.2	Alcance entregado	1
2.3	Definición de terminado	1
3	Historias y criterios de aceptación	2
4	Diseño de la solución	2
4.1	Contexto explícito de fuente	2
4.2	Catálogo de negocio frente a evidencia técnica	3
4.3	Selección semántica universal	3
5	Ejecución y evidencia	3
5.1	Preparación de WideWorldImporters	3
5.2	Propuesta y materialización	4
5.3	Analítica	4
6	Pruebas y riesgos	4
7	Revisión y retrospectiva	5

1. Resumen ejecutivo

El Sprint 6 elimina la selección global de una única base y convierte la fuente de datos en parte explícita de cada artefacto. Una organización puede mantener varias conexiones SQL Server habilitadas y ejecutar, para cada una, el mismo recorrido: captura de metadatos, catálogo, formulación, viabilidad, propuesta, aprobación, ETL, conciliación y analítica.

AdventureWorks2022 y WideWorldImporters se usaron como casos de contraste, no como personalizaciones. El código no decide por el nombre de la base, tabla o columna. La selección se apoya en estructura, función semántica, tipos, claves, relaciones declaradas, granularidad y fórmulas controladas.

Criterio. El catálogo no lo construye libremente la IA. El analista administra la orientación de negocio; la plataforma descubre evidencia técnica por fuente; el LLM interpreta y propone; y validadores determinísticos aceptan o rechazan cada referencia.

2. Objetivo, alcance y definición de terminado

2.1. Objetivo del incremento

Permitir que una misma empresa opere varias fuentes al mismo tiempo, sin desactivar una para consultar otra y sin mezclar metadatos, propuestas, ejecuciones o resultados.

2.2. Alcance entregado

- selector persistente de fuente en el espacio de trabajo;
- conexiones probadas y habilitadas de forma independiente;
- instantáneas, catálogos, propuestas, ETL y analítica filtrados por conexión;
- restauración idempotente de WideWorldImporters para la demostración;
- detección universal de ventas, fecha, producto, cliente, territorio y costo;
- rechazo de rutas de auditoría y evidencia ajena al contexto comercial;
- etiquetas descriptivas en dimensiones, filtros y gráficos;
- documentación y pruebas automatizadas del contrato multifuente.

No se incluyeron pronósticos, combinación de hechos entre bases ni conectores distintos de SQL Server. Estas extensiones requieren contratos y pruebas propias.

2.3. Definición de terminado

1. dos bases pueden permanecer habilitadas simultáneamente;
2. toda petición nueva incluye el identificador de conexión;
3. una instantánea no puede usarse con otra conexión;
4. el catálogo de una fuente no altera el de otra;

5. una propuesta viable no pierde requisitos porque el LLM los omite;
6. el ETL lee la fuente asociada a la propuesta aprobada;
7. la conciliación produce diferencia cero y la analítica muestra procedencia;
8. código, especificación, manual, tesis, bitácora e informe compilan y pasan CI.

3. Historias y criterios de aceptación

Historia	Necesidad	Criterio verificable
MS-01	Elegir una fuente sin afectar a otros usuarios.	La preferencia vive en la sesión del navegador y cada API recibe <code>connection_id</code> .
MS-02	Conservar evidencia separada.	Instantáneas, catálogo, propuestas y ejecuciones pertenecen a una sola conexión comprobada.
MS-03	Entender qué hace la IA en el catálogo.	La interfaz separa preguntas de negocio y cobertura técnica automática.
MS-04	Trabajar con esquemas diferentes.	El motor usa metadatos y FK; no contiene condiciones para AdventureWorks o WideWorldImporters.
MS-05	Evitar relaciones técnicamente válidas pero semánticamente falsas.	FK de auditoría como <code>LastEditedBy</code> se excluyen de las rutas de negocio.
MS-06	Mantener los requisitos solicitados.	Toda capacidad directa o derivable debe quedar cubierta o bloquear la aprobación.
MS-07	Consultar resultados comprensibles.	Los gráficos usan etiquetas materializadas y conservan claves para trazabilidad.

4. Diseño de la solución

4.1. Contexto explícito de fuente

El contrato dejó de depender de una conexión activa global. La tabla de conexión indica si una fuente está habilitada y probada; el contexto elegido acompaña cada consulta. La instantánea constituye la frontera de evidencia y vincula el resto del expediente con la base exacta usada durante la generación.

La migración de datos incorpora el identificador de conexión al catálogo analítico y crea la unicidad por fuente y dominio. Las API de metadatos, asistente, ETL y analítica validan pertenencia antes de devolver o modificar un registro.

4.2. Catálogo de negocio frente a evidencia técnica

Capa	Responsable	Contenido
Orientación funcional	Analista BI	Preguntas, etiquetas, explicaciones y periodicidades por fuente.
Descubrimiento	Plataforma	Tablas, columnas, tipos, PK, FK, rutas y disponibilidad actual.
Propuesta	LLM	Interpretación y borrador de modelo sobre metadatos restringidos.
Aceptación	Motor determinístico	Referencias, cardinalidad, granularidad, fórmulas y cobertura.

La pantalla muestra la instantánea utilizada y, para cada pregunta estándar, si existe evidencia verificable. La configuración funcional nunca convierte una columna inexistente en una capacidad. Una pregunta personalizada orienta al modelo, pero la propuesta debe superar los mismos controles.

La revisión histórica confirmó que las cuatro preguntas iniciales —tiempo, producto, cliente y territorio— fueron definidas por el perfil de ventas de la aplicación, no por el LLM. En AdventureWorks el analista incorporó después dos preguntas personalizadas, **Costos y rentabilidad de las ventas** y **Ventas y costos por unidad**, a partir de recomendaciones conversacionales. WideWorldImporters no hereda esas personalizaciones: parte de la línea base y sólo incorpora preguntas adicionales mediante una decisión humana.

4.3. Selección semántica universal

La búsqueda privilegia un subgrafo comercial coherente. Primero resuelve la tabla de hechos y luego evidencia relacionada para fecha, producto, cliente, territorio y costo. Las coincidencias exactas reciben prioridad sobre coincidencias parciales; compras, históricos, auditoría y tablas temporales reciben penalización o exclusión según su función.

Las dimensiones solicitadas y respaldadas por evidencia se incorporan aunque el proveedor las omita. Las medidas calculadas se reconstruyen con operaciones permitidas. Por ejemplo, ventas puede derivarse de precio por cantidad y costo de cantidad por costo unitario, pero sólo si ambas entradas existen y están conectadas mediante rutas verificadas.

5. Ejecución y evidencia

5.1. Preparación de WideWorldImporters

El contenedor descarga el respaldo oficial cuando no está presente, restaura la base de forma idempotente y conserva el binario fuera de Git. El lector de demostración se agrega a los roles existentes cuyo alcance es ventas. Esto permite que las políticas de seguridad por territorio de la base de ejemplo no oculten clientes durante la prueba. Para fuentes externas, el producto respeta los permisos definidos por el DBA y no los modifica.

5.2. Propuesta y materialización

La propuesta 96 se generó con Claude Haiku 4.5. El proveedor omitió inicialmente elementos y propuso componentes incompatibles; el motor común incorporó dimensiones demostrables, excluyó fórmulas sin evidencia y mantuvo como limitación el descuento no disponible. La aprobación se realizó con cobertura completa de los requisitos viables.

La ejecución 13 materializó el datamart de WideWorldImporters sin modificar el de AdventureWorks:

Control	Resultado
Filas de origen y destino	231.412 / 231.412
Diferencia	0
Pedidos distintos	73.595
Unidades vendidas	9.310.904
Ventas	177.634.276,40
Costo	88.904.313,90
Margen bruto	88.729.962,50
Margen porcentual	49,9509 %
Calidad descriptiva	227 productos, 663 clientes y 53 territorios

La fuente no proporcionó una moneda ISO inequívoca; por ello los importes se rotulan como **moneda de origen**. Presentar USD habría sido una invención. De igual modo, el descuento permanece no disponible.

5.3. Analítica

El tablero obtiene filtros y rankings desde la ejecución seleccionada. La dimensión de territorio conserva la clave, pero presenta nombres como Texas, Pennsylvania, California y New York. Productos y clientes usan los atributos descriptivos materializados. La lista de ejecuciones se filtra por fuente y expone conexión, base, propuesta y ejecución.

6. Pruebas y riesgos

Control	Evidencia
Aislamiento	Catálogo, instantánea, propuesta, ETL y tablero rechazan referencias cruzadas.
Descubrimiento	Ventas actuales prevalecen sobre compras y archivos; auditoría no crea rutas de negocio.
Proveedores	La validación posterior al LLM corrige omisiones y descarta referencias no demostrables.
Materialización	Conciliación de 231.412 filas con diferencia cero.
Dimensiones	Producto 227/227, cliente 663/663 y territorio 53/53 con nombre.
Interfaz	Selector de fuente, cobertura técnica y resultados contextuales probados en React.
Calidad	Ruff, formato, Mypy, Pytest, ESLint, Vitest, Vite y LaTeX forman la puerta de salida.

El riesgo residual principal es que una fuente externa aplique seguridad por fila que oculte datos al lector. Esto no se resuelve elevando privilegios desde la aplicación: debe diagnosticarse y coordinarse con el DBA. También permanece fuera del alcance la traducción automática de significados propios del negocio que no puedan demostrarse por metadatos.

La ejecución formal de los escenarios MS-E2E-01 a MS-E2E-09 se consolidó en `docs/testing/Informe_pruebas_integrales_multifuentes.pdf`. El informe incorpora capturas de las incidencias, repetición post-corrección, conciliaciones de 121.317 y 231.412 filas, verificación visual de todas las páginas PDF e inspección estructural y visual de los libros Excel. La suite final aprobó 157 pruebas de backend y 24 pruebas de frontend, además de formato, análisis estático, tipado, lint y compilación de producción.

El escenario MS-E2E-09 añadió una regresión específica para propuestas históricas. La consulta de evidencia quedó estrictamente en modo de sólo lectura: una diferencia entre la huella persistida y la reconstrucción actual se informa como compatibilidad y no retira una decisión humana. La migración 20261001_18 restauró las propuestas 86 y 91 porque ambas conservaban ejecuciones conciliadas. Datamart de ventas abre por defecto el último expediente publicado y, en AdventureWorks, coincide con Analítica en la ejecución 12 y la propuesta 91.

7. Revisión y retrospectiva

El contraste entre dos modelos OLTP demostró que universalidad no significa reconocer cualquier esquema sólo por semejanza léxica. Significa aplicar el mismo proceso de descubrimiento, evaluación, propuesta, validación, materialización y trazabilidad, y detenerse cuando falta evidencia.

El problema reportado en el catálogo permitió aclarar una responsabilidad clave: la IA no es dueña del catálogo ni de la verdad técnica. Su aporte es interpretativo. La plataforma mantiene el contrato y el analista conserva la decisión de negocio.

Control documental

Campo	Valor	
Código	INF-SPR-06	
Fuente editable	<code>docs/sprints/sprint-06-multifuentes-universal.tex</code>	
PDF oficial	<code>docs/sprints/sprint-06-multifuentes-universal.pdf</code>	
Compilación	<code>make sprint6-report</code> o <code>make docs</code>	
Especificación	<code>SPR-06-01-contexto-multifuentes-sqlserver.md</code>	
Evidencia integral	<code>docs/testing/Informe_pruebas_integrales_multifuentes.pdf</code>	
Definición de termino	Código, pruebas, evidencia real y documentación reproducible.	

Rol	Nombre y conformidad	Fecha
Responsable	_____	_____
Responsable	_____	_____
Tutor/revisor	_____	_____